

DiseaseKG: 基于cnSchma常见疾病信息构建 Knowledge Graph

本项目根据从权威医药网站上爬取的医疗数据，对数据进行处理，从而运用到中文开放知识图谱（**OpenKG.cn**）中，以便需要者直接使用。对获得的医疗数据进行整理，使其可直接用于知识图谱的搭建（**Neo4j**），文件处理成**json**格式。文件分为实体（实体基本信息与属性）和关系（不同实体间关系）两个类别。（本项目借鉴前人智慧，但基于其爬取数据的方法对数据进行了更加充分的使用）

OpenKG链接: <http://openkg.cn/dataset/disease-information>

GitHub链接: <https://github.com/nuolade/disease-kb>

参考GitHub链接: <https://github.com/liuhuanyong/QASystemOnMedicalKG>

文档主要从项目文件介绍、数据获取与处理、知识图谱搭建、生成文件介绍和效果可视化展示五方面对DiseaseKG进行概述性分享，具体细节可以访问我们项目的GitHub主页。

项目文件介绍

```
1  diseaseKG
2  |— data
3  |   |— medical.json 结构化疾病医疗知识
4  |— prepare_data
5  |   |— build_data.py 数据处理到数据库
6  |   |— data_spider.py 爬取数据
7  |   |— max_cut.py 根据给定的词典对文本进行前向、后向和双向最大匹配
8  |— dict 各种类别的词典
9  |— build_medicalgraph.py 利用结构化的数据建立Neo4j知识图谱
10 |— build_medicalgraph_from_json.py 利用实体和关系json文件据建立知识图谱
11 |— build_json.py 利用爬取的数据生成提炼的实体和关系json文件
```

使用方法

1. 数据爬取与处理: `data_spider.py -> build_data.py`
2. 知识图谱搭建（任一方式皆可）：
 - 原始文件搭建知识图谱: `build_medicalgraph.py`
 - 从生成实体关系文件到搭建知识图谱: `build_json.py -> build_medicalgraph_from_json.py`

数据获取与处理

获取

数据从“寻医问药”医疗网站上爬取原始数据，将其保存到本地数据库(MongoDB)中。爬取数据以疾病为单位，获得其各方面的信息，如：成因、症状、服用药物等。爬取时，根据疾病id爬取不同的网站。除疾病外，还爬取了疾病监测的相关数据，也将其保存到数据库中。

处理

对爬取的数据进行预处理，筛选适合做知识图谱知识存储的相关信息。最后从数据库中提取出结构化的文件medical.json，用于搭建知识图谱。

知识图谱搭建

利用结构化的知识，选择相关内容作为实体、关系与属性，搭建Neo4j上的知识图谱。为方便使用，将搭建图谱的实体、关系与属性保存为json格式，即方便搭建知识图谱，也利于阅读。

搭建流程

知识图谱的搭建有两种方式，这两种方式生产的图谱是等价的，用户可任选其中一种完成知识图谱的搭建。

1. 从数据库中导出整理后完整疾病医疗数据medical.json，读取该文件获得各类别实体和关系，搭建知识图谱。
2. 从medical.json提炼出实体与关系的json文件，再通过这两个文件生成知识图谱，这样生成的文件可读性更高。

统计信息

知识图谱主要的包括8类实体共44656条数据，分别为Disease、Drug、Food、Check、Department、Producer、Symptom和Cure；11类关系共312159条数据，分别为belongs_to、common_drug、do_eat、drugs_of、need_check、no_eat、recommand_drug、recommand_eat、has_symptom、acompany_with和cure_way；其中疾病（‘Disease’）实体相较其他实体有额外的属性，分别为name、desc、prevent、cure_lasttime、cured_prob和easy_get。具体如下：

1. 知识图谱实体类型（8类实体）

实体类型	中文含义	实体数量	举例
Disease	疾病	8808	急性肺脓肿
Drug	药品	3828	布林佐胺滴眼液
Food	食物	4870	芝麻
Check	检查项目	3353	胸部CT检查
Department	科目	54	内科
Producer	在售药品	17,201	青阳醋酸地塞米松片
Symptom	疾病症状	5,998	乏力
Cure	治疗方法	544	抗生素药物治疗
Total	总计	44,656	约4.4万实体量级

2. 知识图谱关系类型（11类关系）

实体关系类型	中文含义	关系数量	举例
belongs_to	属于	8,843	<内科, 属于, 呼吸内科>
common_drug	疾病常用药品	14,647	<成人呼吸窘迫综合征, 常用, 人血白蛋白>
do_eat	疾病宜吃食物	22,230	<成人呼吸窘迫综合征, 宜吃, 莲子>
drugs_of	药品在售药品	17,315	<人血白蛋白, 在售, 莱士人蛋白人血白蛋白>
need_check	疾病所需检查	39,418	<单侧肺气肿, 所需检查, 支气管造影>
no_eat	疾病忌吃食物	22,239	<成人呼吸窘迫综合征, 忌吃, 啤酒>
recommand_drug	疾病推荐药品	59,465	<混合痔, 推荐用药, 京万红痔疮膏>
recommand_eat	疾病推荐食谱	40,221	<成人呼吸窘迫综合征, 推荐食谱, 百合糖粥>
has_symptom	疾病症状	54,710	<成人呼吸窘迫综合征, 疾病症状, 呼吸困难>
acompany_with	疾病并发疾病	12,024	<成人呼吸窘迫综合征, 并发疾病, 细菌性肺炎>
cure_way	疾病治疗方法	21, 047	<急性肺脓肿, 治疗方法, 抗生素药物治疗>
Total	总计	312,159	约 31 万关系量级

3. 疾病实体属性类型（7类属性）

属性类型	中文含义	举例
name	疾病名称	成人呼吸窘迫综合征
desc	疾病简介	成人呼吸窘迫综合征简称 ARDS...
cause	疾病病因	化脓性感染可使细菌毒素...
prevent	预防措施	对高危的患者应严密观察...
cure_lasttime	治疗周期	2-4 月
cured_prob	治愈概率	85%
easy_get	疾病易感人群	无特定的人群

生成文件介绍

主要对爬取整理后的完整疾病信息、生成的实体和关系：medical.json、entities.json和relations.json三个文件进行介绍（具体查看文件）。

medical.json文件说明

此文件包含8808条爬取并处理后的完整疾病医疗数据，其为从数据库中导出的结构化文件，包含疾病ID、名称、类别、成因、症状、药物和检测等相关数据。medical.json一条疾病数据大致信息如下：

```
1 { "_id" : { "$oid" : "5bb578b6831b973a137e3eff" },
2
3   "name" : "肺水肿","desc" : "肺水肿(pulmonaryedema)是指由于...",
4   "category" : [ "疾病百科", "内科", "呼吸内科" ],
5   "prevent" : "进入高原前多了解高原...", "cause" : "接触高原的状况：是初次进...", "symptom" : [ "湿啰音"... ], "yibao_status" : "否",
6   "get_prob" : "0.05%", "easy_get" : "多见于重症肺炎患者",
7   "get_way" : "无传染性", "acompany" : [ "弥散性血管内凝血" ],
8
9   "cure_department" : [ "内科", "呼吸内科" ], "cure_way" : [ "药物治疗", "支持性治疗" ], "cure_lasttime" : "3-6周", "cured_prob" : "75%治愈率", "common_drug" : [ "氨茶碱片", "呋塞米片" ], "cost_money" : "市三甲医院约（6000 — 20000元）...",
10
11  "check" : [ "胸部平片"... ], "do_eat" : [ "鸡肝", "杏仁", "松子仁"... ], "not_eat" : [ "螃蟹", "海蟹", "海虾"... ], "recommand_eat" : [ "肉卤鸡蛋", ... ], "recommand_drug" : [ "呋塞米片"... ],
12  "drug_detail" : [ "太原振兴氨茶碱片(氨茶碱片)"... ] }
```

entities.json文件说明

此文件包含8类实体共44656条数据，其中疾病（‘Disease’）相较其他实体有额外的属性，而其他类实体无其他属性。entities.json中一条数据信息构成如下（以Disease和Food实体为例）：

```
1  {
2      "label": "Disease",
3      "name": {
4          "name": "肺泡蛋白质沉积症",
5          "desc": "肺泡蛋白质沉积症(简称PAP)，又称Rosen-Castle-man-
Liebow综合征...",
6          "prevent": "1、避免感染分支杆菌病，卡氏肺囊肿肺炎，巨细胞病毒
等...",
7          "cause": "病因未明，推测与几方面因素有关：如大量粉尘吸入（铝，
二氧化硅等）...",
8          "easy_get": "",
9          "cure_department": "",
10         "cure_way": "",
11         "cure_lasttime": "约3个月",
12         "symptom": "",
13         "cured_prob": "约40%",
14         "get_prob": "0.00002%"
15     }
16 }
17
18
```

```
1  {
2      "label": "Food",
3      "name": "胡萝卜番茄汤"
4  }
```

relations.json文件说明

此文件包含11类关系共312159条数据，每一类关系为一个字典，信息包括开始实体类型、结束实体类型、关系类型、关系名称、关系集合；关系集合中包括了该类关系的所有关系，信息包括开始实体名称与结束实体名。relations.json中一条数据信息构成如下（以Disease-recommand_eat-Food为例）：

```
1  {
2    "start_entity_type": "Disease",
3    "end_entity_type": "Food",
4    "rel_type": "recommand_eat",
5    "rel_name": "推荐食谱",
6    "rels": [{
7      "start_entity_type": "Austin型幼儿脑磷脂病",
8      "end_entity_type": "鸭肉",
9    }, ...]
10 }
```

效果可视化展示

DiseaseKG项目实现了Neo4j上的知识图谱，下图为某一检索效果：

